Bàn giao Việc 1: Chuẩn hoá câu hỏi (question_norm)

Cập nhật: 04/11/2026. Người giữ module: Ngân (bản gốc). Đình Việt và Claude đã vá thêm 2 lần.

1. File nào là bản chính thức

File trên Drive (`datalayer/code/`)	Vai trò
`question_norm_ngan.py`	**Bản chính thức**, đã áp ô vá 1–6. Khi nhóm chốt thì đổi tên thành `question_norm.py`.
`question_norm_ngan_goc.py`	Bản gốc của Ngân trước khi vá, để đối chiếu. Không dùng.
`question_norm.py` (32 KB, v5 của Việt)	Bản cũ. Nên đổi tên thành `question_norm_viet_v5.py` để khỏi nhầm. Không dùng.
`question_norm_v1..v4_backup.py`	Bản lưu cũ của Việt. Không dùng.
`time_gold.py`	Bộ gold 100 câu của Ngân (do Claude soạn, chưa có người duyệt).
`value_norm.py`, `value_parsers.py`	Module chuẩn hoá giá trị (parse_money/qty/date), **khác** module này.

Không file nào ở trên đọc hay sửa dữ liệu gốc của BTC.

2. Cách dùng

```
import sys, json; sys.path.insert(0, CODE)
import question_norm_ngan as qn                    # sau khi đổi tên: import question_norm
as qn
train_q = [json.loads(l) for l in open(TRAIN + '/questions.jsonl', encoding='utf-8')]
qn.VOCAB = qn.build_vocab(train_q)                 # BẮT BUỘC: bật sửa chữ gõ Telex
('tieenf' -> 'tiền')
r = qn.normalize_question(cau_hoi, as_of_date, calendar_data)   # calendar_data = list dict
đọc từ calendar.csv
```

Lưu ý: `build_vocab` chỉ **trả về** từ vựng, nên phải gán vào `qn.VOCAB`. Nếu quên dòng này, module vẫn chạy nhưng không sửa được lỗi gõ Telex.

3. Đầu ra của `normalize_question`

Trường	Ý nghĩa
`text_norm`, `text_ascii`	Câu đã mở rộng viết tắt / sửa Telex, và bản bỏ dấu
`periods`	Danh sách kỳ thời gian (xem dưới)
`amounts`	Tiền / %: `{span, value, unit, op, role}`; `unit` là `vnd`, `percent` hoặc `number` (số có dấu ngăn nghìn mà không có đơn vị, kèm `maybe_money`)
`numbers`	Số đếm khác: `{span, value, next}` (ví dụ "top 3", "từ 187 đơn")
`flags`	Cờ ý định: so_sanh, tang_truong_pct, top1, topk, can_gia_von, ca_lam, no_cong_no, ton_kho_han_dung, ty_le_ty_trong, trung_binh, gio_cao_diem
`time_failed`	`True` = có từ khoá thời gian mà luật không hiểu. **Bước sau nên bỏ qua câu này (abstain, 0 điểm) thay vì đoán (−1).**
`time_cues`	Các từ khoá thời gian tìm thấy (để gỡ lỗi)

Mỗi kỳ trong `periods`

- `label`:
  - `ky_nay` là kỳ chính.
  - `ky_truoc` là kỳ để so sánh.
  - `ky_khac` là kỳ phụ khác có trong câu.
  - `ky_1`, `ky_2`, … là chuỗi tháng liên tiếp, ví dụ "từ tháng 8 tới tháng 10". **Cần người làm bước truy vấn xác nhận.**
- `start`, `end`: ngày ISO, tính cả hai đầu. `start = null` nghĩa là tính **từ đầu dữ liệu** (mốc cuối ngày).
- `kind`: month, day, date, month_to_date, week, week_to_date, quarter, quarter_to_date, ytd, year, range, rolling, snapshot, tet, pre_tet, fwd_window, back_window, forward_days, month_in_range.
- Có thể có thêm:
  - `semantics`: `within` hoặc `snapshot_end`.
  - `time_start` / `time_end` cho ca sáng 06:00–13:59 và ca chiều 14:00–21:59.
  - `needs_data: "price_increase_date"`: câu "kể từ khi tăng giá" mà không ghi ngày. Bước sau phải tự tìm ngày đổi giá trong dữ liệu.
  - `note`: ghi chú về cách hiểu đã chọn.

Mỗi số tiền trong `amounts`

- `op`: `gte` ("từ N trở lên", "ít nhất", ≥), `gt` ("trên/hơn/quá N", không gồm N), `lte`, `lt`, hoặc `null`.
- `role`: `new_price` ("lên giá 23.000đ"), `old_price` ("từ 22.000đ lên ..."), hoặc `null`.

4. Ví dụ thật

Câu (as_of)	periods	amounts
"th5/2026 shop mik bn don dthu dat tu 3tr7 tro len z ha" (10/06/2026)	ky_nay 2026-05-01→05-31	3.700.000 vnd, op gte
"Tồn kho cuối ngày hôm nay Otrivin 0,1% còn bao nhiêu chai?" (10/03/2026)	ky_nay null→2026-03-10 (snapshot)	không có (0,1% là tên hàng)
"So cùng kỳ năm trước, doanh thu tháng 5/2026 tăng/giảm mấy %" (02/06/2026)	ky_nay 2026-05, ky_truoc 2025-05	không có
"Tuần trước ca chiều so với ca sáng thì doanh thu chênh bao nhiêu %" (12/03/2026)	2 kỳ cùng tuần 02/03→08/03, ky_nay ca chiều, ky_truoc ca sáng	không có
"Kể từ khi Prospan lên giá 97.500 đồng/chai, 14 ngày đầu ... 14 ngày liền trước"	fwd_window và back_window, `needs_data`	97.500 vnd, role new_price
"doanh thu 8/26" (19/09/2026)	ky_nay 2026-08-01→08-31 (từ ô vá 4)	không có

5. Kiểm thử và số liệu đã đo

Chạy `qn.run_tests()`, mong đợi **Đạt 934/934** (838 ca của Ngân + 96 ca cho các điểm vá).

Đo trên bản sao ngày 04/11:

Thước đo	Bản gốc Ngân	Sau 2 ô vá
Test đơn vị	838/838	934/934
Gold Ngân (`time_gold.py` , 100 câu)	100/100	100/100
Bộ 54 câu ngoài TRAIN (`ood_tests.py`)	49/54	54/54
TRAIN 3000 câu có `time_failed`	0	0
TRAIN không ra kỳ nào	13 câu	13 câu (câu không hỏi thời gian, hoặc cần dữ liệu)
Độ bền, câu gõ Telex lỗi: kỳ thời gian / số tiền	99,95% / 98,74%	99,95% / 100%

Lưu ý trung thực:

- Cả gold 100 câu lẫn bộ 54 câu đều do Claude soạn, nên điểm cao chưa chứng minh được là đúng.
- Bộ độ bền sinh biến thể từ chính câu TRAIN.
- Cần một người trong nhóm duyệt lại, và chưa dùng PUBLIC để chỉnh luật.

6. Những gì các ô vá đã sửa (so với bản gốc Ngân)

1. "Cuối ngày (hôm nay / X)" trong câu hỏi **số còn lại** (tồn, nợ, còn hàng) là mốc cuối ngày, start = null. Câu hỏi phát sinh (doanh thu, số đơn, bán được) vẫn tính trong ngày, theo đúng rulebook.
2. "Từ tháng X đến/tới tháng Y" trả đủ các tháng ở giữa. "N tháng liền nhau kết thúc ở tháng X" trả N tháng.
3. Các cách nói thời gian khác:
   - "Tuần/tháng/quý trước nữa" lùi 2 kỳ.
   - "Năm 2025" đứng riêng là cả năm.
   - Khoảng ngày có gạch nối ("01/02/2026 – 15/02/2026") được nhận.
   - "Từ nay đến hết ngày X" là khoảng từ hôm nay đến X.
   - "Cùng tháng năm trước" là cùng tháng của năm trước, không phải tháng liền trước.
4. Số tiền gõ Telex ("23.000dd", "41.000 ddoongf") được nhận là vnd. "2 tỷ/5ml" không còn bị đọc là tiền.
5. Dấu % trong tên hàng ("Otrivin 0,1%", "kem 5%") không còn bị coi là câu hỏi %. "Giảm đau" không còn bị coi là "giảm".

6. Bộ sửa chính tả từ khoá thời gian không còn đổi nhầm "thuốc" thành "trước" (110 lần trong TRAIN), "thùng", "thân", "trăng" thành "tháng", "quầy" thành "quý".
7. Số tiền có thêm `op` và `role`.

Chỗ nào sửa trong code đều có ghi chú `[vá]`. Hai ô vá năm ở `o_va_ngan_1.py` và `o_va_ngan_2.py`.

Ô vá 3 (theo bảng chấm tay 200 câu tự sinh, `o_tu_sinh_cau_hoi.py`)

8. Cách nói mơ hồ → `time_failed` (bỏ qua, 0 điểm) thay vì đoán sai hoặc không báo: sáng nay, tối qua, 3 ngày trước, tuần sau, mấy hôm nay, gần đây, dạo này, đầu/cuối/giữa tháng, cuối tuần, tuần đầu tiên. Câu có một cụm không hiểu thì bỏ qua cả câu.
9. Cách nói mới: nửa đầu/cuối tháng (1–15 / 16–cuối tháng), "từ 15 tới 20 tháng này", "từ thứ Hai tới giờ", "thứ Bảy tuần trước", "2 hôm nay" (= 2 ngày gần nhất), "mùng N Tết" (tra calendar.csv), số viết chữ gõ Telex ("bayr ngày").
10. Tiền lóng (Việt xác nhận): củ/chai = 1 triệu, lít/xị = 100 nghìn, cá/cành/k = 1 nghìn, tỏi = 1 tỷ, "rưỡi" = +0,5 (2 triệu rưỡi = 2.500.000). Vì chai/lít/củ/tỏi/cá cũng là đơn vị hàng thật, chỉ nhận là tiền khi ngay trước có chữ chỉ tiền (giá, chỉ, tiền, doanh thu…) hoặc toán tử (trên, dưới…); riêng chai/lít bắt buộc có chữ chỉ tiền.
11. "Cùng kỳ năm trước" đứng một mình không còn bị lấy làm kỳ chính (trước đây "tối qua … so với cùng kỳ năm trước" ra cả năm 2025).

Ô vá 4–6

12. Bật kiểu viết tháng/năm 2 chữ số "8/26" (Việt đồng ý 05/11).
13. Câu hỏi phát sinh (doanh thu, số đơn, bán được) + "tính đến / đến hết X" mà không có "từ …" → bỏ qua (rulebook không định nghĩa; Việt đồng ý 05/11). "từ D đến hết hôm qua" giờ hiểu được.
14. Câu hỏi số còn lại (tồn kho, còn nợ, còn hàng) + tháng/quý/năm/tuần/Tết → mốc cuối kỳ, tính từ đầu dữ liệu; kỳ chưa hết thì mốc hôm nay (Việt chọn 05/11).
15. "chai", "lít" trong câu đếm hàng không bị đọc thành tiền ("bán 3 thùng 10 chai", "tồn kho còn 10 chai"); chữ chỉ tiền phải là từ trọn ("thu" không khớp trong "thùng").
16. Cách nói đồng nghĩa bị ô 3 và 5 chặn oan: "tháng/năm/tuần/quý này tính tới hôm nay", "từ mùng 1 tới hết hôm nay", "đầu năm tới giờ/chừ", "cùng số ngày đầu tháng trước", "giữa tháng 1, 2 và 3" (= trong các tháng đó), "N ngày từ bữa đó", "3 tháng liền nhau tính tới 3-2026", "từ khi X lên giá, N ngày đầu" (cần ngày tăng giá trong dữ liệu).
17. "sau hôm nay" không còn bị đọc thành "sáu hôm nay" (6 ngày gần nhất). Lưu ý: Việc 1 chỉ trả mốc ngày; chiều so sánh ("hạn trả trước/sau hôm nay", "đã quá hạn") bước sau phải tự đọc từ câu hỏi.

Luật chấm điểm của BTC (đáp án phải đúng format): xem `luat_cham_diem.md`. Việc 1 không ghi đáp án, nhưng phải giữ nguyên tên hàng/khách và đơn vị hàng (thùng, chai, hộp) để bước sau quy đổi theo bảng của shop.

Lưu ý khi chạy ô vá: chạy mỗi ô **một lần, theo thứ tự 1→9**. Nếu lỡ chạy lại ô vá 1 sau ô vá 2, chạy `o_sua_chay_lai.py` để gỡ đoạn chèn lặp.

7. Điểm còn mở, chờ nhóm chốt

1. **Nhãn `ky_1, ky_2…`** cho chuỗi tháng: bước truy vấn có đọc được không?
2. **Cách hiểu tự suy luận** (rulebook không nói rõ). Việt đã chốt (05/11): "quý này" = đầu quý→hôm nay; "năm nay" = 01/01→hôm nay; "2 tuần gần nhất" = 14 ngày tính lùi kể cả hôm nay. Code đang làm đúng như vậy. Còn mở:
   - ~~"tồn kho … quý II còn bao nhiêu"~~: đã chốt là mốc cuối quý (ô vá 6).
3. ~~Kiểu viết "8/26"~~: **đã bật** (ô vá 4, Việt đồng ý 05/11). "8/26" = tháng 8/2026, chỉ khi số sau trong khoảng 20–40.
4. **Đổi tên file** để chỉ còn một `question_norm.py` chính thức.
5. **Một người trong nhóm duyệt gold**, vì gold hiện do Claude soạn.