Bàn giao Việc 2: Làm sạch bảng

Gửi: Leader (Việc 3) · **Người giữ module:** Nhi · **Cập nhật:** 05/11/2026

Tài liệu này chỉ ghi những gì đã chạy hoặc đã kiểm chứng. Chỗ nào chưa chắc đều năm ở mục 7.

1. Tóm tắt trong 30 giây

- **Việc 2 làm gì:** đọc mọi file của một shop (xlsx, csv, sqlite), tìm dòng tên cột, làm sạch giá trị tiền / ngày / số lượng, gộp các sheet cùng cấu trúc thành bảng. Hàm vào là `load_clean_tables(thư_mục_shop)`.
- **Đã chạy được:** cả 44 shop (30 train, 14 public) không văng lỗi. Tổng 225 bảng, 5.323.809 dòng, mất khoảng 19 phút.
- **Chưa chứng minh:** dữ liệu đúng 100%. Chưa so với đáp án train (`answers.jsonl`); mới kiểm bằng mắt 1 shop (biz_111).
- **Cần Leader quyết định 3 việc** (chi tiết ở mục 6): dùng `Tổng bill` hay tổng các dòng làm doanh thu; xác nhận cho dùng `dq_runner.py` thay Ô 7; cho phép chốt các file vào `ban_giao/`.

2. Cách dùng

```
import sys; sys.path.insert(0, CODE)
import clean_shop, value_parsers as vp

tables, meta = clean_shop.load_clean_tables(TRAIN + '/data/biz_111')

vp.parse_money('5tr520')    # 5520000
vp.parse_money('1,5')       # None (mơ hồ, không đoán)
vp.parse_qty('1,5 kg')      # (1.5, 'kg')
vp.parse_date('15.07.2025') # '2025-07-15'
vp.parse_date('31/11/2025') # None (ngày không tồn tại)
vp.run_tests()              # phải in: Đạt 126/126 ca kiểm thử
```

Chạy cả 44 shop và xuất báo cáo (khoảng 19 phút):

```
import dq_runner
rep, col = dq_runner.run([('train', TRAIN), ('public', PUBLIC)], DL +
'/outputs')
```

Lưu ý khi sửa code: ghi file bằng `%%writefile`, copy lên Drive, rồi mới `importlib.reload`. Làm ngược thứ tự thì Colab vẫn nạp bản cũ (đã gặp một lần).

3. Việc 3 nhận được gì

`load_clean_tables` trả về hai thứ: `tables` và `meta`.

3.1 `tables`: `{tên bảng: DataFrame}`

Loại cột	Dạng đầu ra	Ghi chú
Tên cột	Giữ nguyên tên gốc	Việc 2 không đổi tên sang tên chuẩn
Tiền	Số nguyên VND, kiểu `Int64`	Ô không đổi được thì để trống và có cảnh báo
Ngày	Chuỗi `YYYY-MM-DD`	Cột có giờ: `YYYY-MM-DD HH:MM:SS`
Số lượng	Số	Đơn vị tách sang cột `<tên cột>__don_vi` (ví dụ `SL__don_vi`)
Mã định danh (SĐT, IMEI, MST, barcode)	Để nguyên dạng chuỗi	Cố ý, tránh mất số 0 đầu
Cột trạng thái (Hoàn thành, Huỷ đơn, Đổi trả…)	Để nguyên	Ý nghĩa do rulebook quyết định
3 cột truy vết thêm	`_source_file`, `_source_sheet`, `_sheet_year`	Cho biết dòng đến từ file/sheet nào

3.2 `meta`

Khoá	Ý nghĩa
`warnings`	Danh sách cảnh báo: ô nào không đổi được, kèm 3 ví dụ

Khoá	Ý nghĩa
`date_from`, `date_to`	Khoảng ngày giao dịch. **Không tính** hạn dùng (HSD), ngày sinh, "tạo lúc"
`date_from_all`, `date_to_all`	Khoảng ngày của **mọi** cột ngày, kể cả hạn dùng (nên có shop đến năm 2029)
`tables[bảng]`	Thông tin từng bảng (xem bên dưới)

Mỗi bảng trong `meta['tables']` có:

Khoá	Cho biết
`rows`, `n_parts`, `files`	Số dòng, số sheet đã gộp, các file nguồn
`money`, `date`, `qty`	Cột nào được nhận là tiền, ngày, số lượng
`ffilled`	Cột nào bị điền ô trống (điền theo cấp đơn)
`date_ranges`	Khoảng ngày của từng cột ngày
`status_values`	Các giá trị của cột trạng thái
`unparsed`	Cột nào có ô không đổi được, và bao nhiêu ô
`skipped`	Cột trông giống tiền hoặc ngày nhưng bị bỏ qua vì quá nhiều ô lỗi
`numeric_text`	Cột toàn chữ số mà hàm cố ý không đổi (thường là SĐT, mã)

4. Ranh giới giữa Việc 2 và Việc 3

Việc 2 làm	Việc 2 **không** làm (để Việc 3 / rulebook quyết)
Đổi giá trị tiền, ngày, số lượng sang dạng chuẩn	Đổi tên cột sang tên chuẩn
Tìm dòng tên cột, bỏ dòng tiêu đề lặp và dòng tổng cuối bảng	Quyết định ý nghĩa cột trạng thái (đơn huỷ, đổi trả…)

Việc 2 làm	Việc 2 **không** làm (để Việc 3 / rulebook quyết)
Gộp sheet cùng cấu trúc, thêm cột truy vết	Quy đổi đơn vị (ly, thùng, chai…), chỉ tách ra cột `__don_vi`
Cảnh báo khi không đổi được	Sửa lỗi chính tả trong cột chữ (tên hàng, tên khách…)

Nguyên tắc chung: **không hiểu thì để trống hoặc để nguyên và cảnh báo, không đoán.**

5. Kết quả đã đo

Thước đo	Bản gốc v1.0	Bản hiện tại
Test đơn vị	72/72	**126/126** (tiền 61, số lượng 31, ngày 34)
Chạy 44 shop không lỗi	44/44	44/44 (30 train, 14 public)
Quy mô	chưa ghi	225 bảng, 5.323.809 dòng
Thời gian chạy cả 44 shop	khoảng 12 phút	khoảng 19 phút (chậm nhất dev_008: 113 giây)
Shop có cảnh báo	chưa ghi	23 shop (14 train, 9 public), tổng 202 cảnh báo. Cao nhất: biz_122 (21), biz_118 (20), dev_005 (19)
biz_111	8.300 + 4 ô không đổi được	0 cảnh báo
Bảng bị lỗi font tên	chưa ghi	0 shop

Lỗi quan trọng nhất đã sửa: cột giá bị nhận nhầm là cột ngày

Chuỗi 5 chữ số như `45000` bị coi là số ngày Excel (45000 = 15/03/2023). Giá lẻ thường nằm trong 20000–80000 nên cả cột bị đổi thành ngày, còn giá ngoài khoảng (7000, 10000) bị xoá thành trống. Ở biz_111: 8.300 ô cột `Giá đơn vị` (bảng `chi_tiet_don`) và 4 ô cột `Giá` (bảng `san_pham`). Cách sửa: chuỗi toàn chữ số chỉ được tính là ngày khi **tên cột trông giống cột ngày**. Sau sửa, biz_111 còn 0 cảnh báo.

Kiểm tra bằng mắt: biz_111

Hai phép đo dưới đây chạy **trước khi chốt bản cuối** của `clean_shop`, cần chạy lại một lần.

Phép kiểm tra	Kết quả
Số lượng quy đổi × Giá đơn vị = T.Tiền	98,0% dòng khớp; 2.168 / 106.585 dòng lệch
Tổng T.Tiền các dòng = Tổng bill	90,2% đơn khớp; 6.518 / 66.469 đơn lệch; ghép được 66.469/66.469 đơn
Ví dụ đơn nhiều dòng (ORD000006)	10.000 + 105.000 + 64.000 = 179.000 = Tổng bill; khách trả 179.000, còn lại 0

Các dòng lệch có cùng dạng: `T.Tiền` thấp hơn số lượng × giá đúng một khoản tròn nghìn mỗi đơn vị (2.000–3.000). Các đơn lệch hầu hết có `Tổng bill` cao hơn tổng các dòng đúng 15.000 và khách đã trả đủ. Đây là số liệu trong sổ sách của shop, **không phải lỗi đọc số**. Nguyên nhân (giảm giá theo dòng, phí giao hàng 15.000…) **chưa xác nhận**.

6. Điều cần Leader quyết định / xác nhận

#	Việc	Vì sao cần
1	**Doanh thu tính theo `Tổng bill` hay theo tổng `T.Tiền` các dòng?**	Ở biz_111 hai số lệch nhau ở khoảng 10% số đơn
2	Nguyên nhân khoản lệch 15.000 (phí ship?) và lệch 2.000–3.000 mỗi đơn vị (giảm giá?)	Việc 2 chỉ đo được, không tự kết luận. Cần đối chiếu rulebook
3	Xác nhận dùng `dq_runner.py` thay Ô 7 gốc	Leader đã dặn không sửa Ô 7
4	Xác nhận các sửa trong `clean_shop.py` (cột giá không còn thành ngày)	Để chốt bản và copy vào `ban_giao/v0.X/`
5	Cột chữ có lỗi chính tả (tên hàng, tên khách, phương thức thanh toán): có cần cột khoá so khớp không dấu, chữ thường bên cạnh cột gốc không?	Việc 2 hiện giữ nguyên. Việc 3 quyết định cách dùng

7. Việc chưa chắc và rủi ro đã biết

7.1 Chưa chứng minh được là dữ liệu đúng

- “Chạy không lỗi” không có nghĩa dữ liệu đúng 100%. **Chưa so với đáp án train.**
- Mới kiểm băng mắt 1 shop (biz_111); README yêu cầu 3 shop khác kiểu nhau.
- Các phép đo ở biz_111 (mục 5) chạy trước khi chốt bản cuối, cần chạy lại.
- Mọi chỉnh sửa luật đến nay dựa trên shop train; chưa dùng PUBLIC để chỉnh luật.
- Kiểu dữ liệu ở mục 3 mới kiểm băng shop giả lập, chưa kiểm lại trên toàn bộ dữ liệu thật.

7.2 Hành vi cần biết khi dùng đầu ra

Các điểm dưới đây xác nhận băng dữ liệu giả lập, **chưa gặp trên dữ liệu thật**:

Tình huống	Hành vi hiện tại	Cách phát hiện / tránh
Dòng cuối bảng có ô đầu bắt đầu bằng `tổng`, `cộng`, `total`, `note`, `ghi chú`…	Bị coi là dòng tổng và **bị bỏ**. Hàng thật như `Notebook A4`, `Tong hop vitamin` ở dòng cuối cũng bị bỏ	Số dòng bị bỏ có trong thông tin nội bộ nhưng **chưa đưa ra** `meta`. So số dòng đầu vào với đầu ra nếu cần chắc
Cột ngày có giờ	Có thể lẫn `2025-01-02` và `2025-01-01 10:30:00` trong cùng cột (ô nửa đêm không có giờ)	Dùng 10 ký tự đầu khi so ngày
Số tiền lẻ	Số thật `45000.5` làm tròn lên `45001`, nhưng chuỗi `'45000.5'` trả trống	Chưa chốt cách xử lý thống nhất
Ngày `1/2/2025`	Luôn hiểu là ngày/tháng (1 tháng 2)	Chỉ đổi sang tháng/ngày khi số thứ hai > 12
Ngày có múi giờ `Z`	Bỏ múi giờ, giữ nguyên ngày	Ngày theo giờ Việt Nam có thể lệch 1 ngày với giờ UTC
Năm 2 chữ số (`1/2/99`)	Ra năm 2099	Dữ liệu thật có lẽ không gặp

Tình huống	Hành vi hiện tại	Cách phát hiện / tránh
Tên cột viết khác nhau giữa các sheet (hoa/thường, dư khoảng trắng)	Có thể tách thành hai cột, mỗi cột trống một nửa	Chưa xác nhận trên dữ liệu thật; kiểm `tables[...].columns`

7.3 Rủi ro đã biết, chủ ý giữ

Chuỗi 5 chữ số trong cột có tên **không giống cột ngày** sẽ không bị đổi thành ngày (để tránh nhầm với giá). Nếu một shop dùng cột ngày dạng số serial với tên lạ, cột đó sẽ năm trong `numeric_text` và `dq_columns.csv` để xem lại.

8. Việc làm tiếp theo (theo thứ tự)

1. **Rà 23 shop còn cảnh báo.** Mỗi shop xem 3 ví dụ ở `meta['warnings']` và `dq_columns.csv` (138 dòng), rồi quyết định sửa hàm hay bỏ qua. Ví dụ biết trước: biz_102, biz_103 có ô không đổi được ở cột "Số lượng sản phẩm" (4 và 1 ô). Ưu tiên shop train.
2. Chạy lại các phép đo biz_111 với bản `clean_shop` hiện tại; kiểm băng mắt thêm 2 shop khác kiểu (ví dụ nhiều sheet theo tháng, và shop có bảng lô hàng).
3. Chốt nguyên nhân hai khoản lệch ở mục 6 cùng Leader.
4. Thêm test vào file chính thức: 16 ca biên ở Ô 99 (Ô này đang báo lỗi vì tham chiếu sai tên biến, chưa chạy) và 2 ca test cột vào `MONEY_TESTS`, `QTY_TESTS`, `DATE_TESTS`.
5. So với repo của SWE: hỏi cách gọi `loader.py`, chạy 5 shop, so số bảng, số dòng, tên cột (README mục 8, bước 5).
6. Ghi lỗi cột giá vào sheet "Họp & Vướng mắc"; sau khi Leader xác nhận (mục 6, việc 3–4) thì copy 3 file vào `ban_giao/v0.X/` và nhắn nhóm.

9. File nào là bản chính thức

File (`datalayer/code/`)	Vai trò
`value_parsers.py`	**Bản chính thức** (Ô 11, đã copy lên Drive). Đổi tiền, số lượng, ngày. Kèm 126 ca kiểm thử
`clean_shop.py`	**Bản chính thức** (Ô 22, đã copy lên Drive). Đọc file, tìm tên cột, làm sạch giá trị, gộp sheet

File (`datalayer/code/`)	Vai trò
`dq_runner.py`	**Mới.** Chạy cả 44 shop, ghi `dq_report.csv` và `dq_columns.csv` vào `datalayer/outputs/` . Thay Ô 7 gốc, cần Leader xác nhận
Các ô ghi “Gốc” (đã comment)	Bản v1.0 của Leader, giữ để đối chiếu. Không dùng

Không file nào ghi vào dữ liệu gốc: `clean_shop` chỉ đọc thư mục shop, `dq_runner` chỉ ghi vào thư mục outputs.

10. Phụ lục: những gì đã sửa so với bản gốc của Leader

- **`value_parsers.py`** : nhận số tiền có `vnd` hoặc `đ` đứng trước số; số tiền lớn hơn 10^{13} coi là rác; ngày viết liền `YYYYMMDD` ; ngày có múi giờ; mở rộng cách viết số lượng; bộ kiểm thử tăng từ 72 lên 126 ca.
- **`clean_shop.py`** : nhận biết tên cột (ngày, tiền, số lượng, hạn dùng) không phân biệt dấu; loại hạn dùng, ngày sinh, “tạo lúc” khỏi khoảng ngày giao dịch; sửa tên bảng bị lỗi font; thêm khoá `unparsed` , `skipped` , `numeric_text` , `date_from_all` , `date_to_all` vào `meta` .
- **`dq_runner.py`** : báo cáo thêm số bảng, số dòng, bảng lớn không có cột tiền, cột bị điền ô trống; thêm `dq_columns.csv` liệt kê từng cột có vấn đề.